

固定资源约束下轻量能力胶囊的周期性能、量化保真与精确度衰减实验设计

Capability Capsule Project · 预注册实验方案 v0.1 · 2026-09-09

摘要

本文提出一套面向轻量能力胶囊的分阶段实验协议，用于比较 0.8B 与约 1.5B/2B 非思考型本地模型在 LoRA 后训练、量化部署、固定总内存和多类型离线任务周期下的端到端表现。方案将当前工程选型与后训练完整衰减研究分离：前者用于低成本筛选基础模型，后者用于估计量化非劣效性、知识树半径扩张下的准确率衰减，以及本地模型相对 Teacher 与云端上限模型的能力保留率。为解决单模型必须跑满周期导致的高时间成本，本文采用固定任务事件轨迹、逻辑时间加速回放、设备分层与目标设备实时耐久验证的三级方法。质量结论基于同任务配对实验，性能结论按设备分层报告，禁止用高端服务器吞吐直接替代目标笔记本部署结果。

关键词：能力胶囊；LoRA；量化；知识树半径；离线周期；非劣效检验；硬件分层；Agent 评测



图 1 分阶段实验与设备分层验证流程

1 研究目标与适用阶段

完整实验的主要对象是已经完成 LoRA 后训练并具备可部署量化版本的候选模型，而不是当前尚未训练的工程骨架。当前阶段仅执行缩短版工程选型实验，用于确认训练数据、工具协议、计时、资源采集和评测器是否可靠，并在 0.8B 与约 1.5B/2B 候选中淘汰明显不可用方案。Teacher 模型、GPT-6 Astra 等云端模型以及完整精确度衰减曲线进入后训练阶段，避免同时改变模型、数据、量化、硬件和评测任务而失去因果可解释性。

阶段	研究对象	主要问题	最低产物
I 当前工程筛选	未微调小模型与当前 4B 运行基线	工具协议是否可用；速度是否进入可接受区间	锁定数据格式、周期格式、资源采集
II LoRA 可行性	未训练对照与高精度 LoRA	后训练增益是否稳定；0.8B 是否非劣于更大候选	3 个训练种子、配对结果
III 量化与衰减	高精度 LoRA、量化基础模型加 Adapter	量化损失、知识半径与离线时长衰减	完整逻辑周期、衰减曲线
IV 上限对照	Teacher、云端上限模型、本地胶囊	能力保留率与跨模型差距	盲评、可执行验证、上限差距图

表 1 分阶段实验边界

2 研究问题与预注册假设

- RQ1: 在固定总内存和统一任务事件周期下，0.8B 模型能否以显著更低的延迟维持与约 1.5B/2B 模型可接受的质量差距？
- RQ2: LoRA 后训练相对同基础模型未训练对照能否产生稳定、跨训练种子的任务成功率提升？
- RQ3: 量化基础模型加 Adapter 相对高精度 LoRA 参考是否满足预设非劣效界限？
- RQ4: 离线覆盖时长、任务类型广度和知识树半径增加时，模型的限时成功率如何衰减？
- RQ5: 0.8B 与更大候选的性能差距是否随离线周期扩大，其增长是否具有统计显著的模型乘时间交互效应？

预注册假设包括：H1，离线覆盖窗口扩大将提高任务分布熵和知识树半径，并降低限时成功率；H2，LoRA 将提高核心任务范围内的成功率，但不能消除分布外衰减；H3，0.8B 的 token 吞吐更高，但端到端任务时间不一定更短；H4，不同模型的差距可能随周期扩大，方向和幅度由交互项检验，而不预先设为必然结论；H5，固定总内存下存在模型权重容量与外部知识、KV Cache、工作状态容量之间的 Pareto 权衡。

3 实验对象、基线和对照组

标识	组别	模型状态	用途
A0	运行基线	当前 qwen3.5:4b, 非思考	提供现有系统质量与目标设备耗时锚点
C1	对照组	0.8B, 未微调	估计 0.8B 原始能力
C2	对照组	约 1.5B/2B, 未微调	估计更大候选原始能力
E1	实验组	0.8B + LoRA, 高精度	估计 0.8B 的后训练增益
E2	实验组	约 1.5B/2B + LoRA, 高精度	估计更大候选的后训练增益
Q1	部署组	量化 0.8B + 同一 Adapter	评估轻量胶囊实际部署表现
Q2	部署组	量化较大候选 + 同一 Adapter	评估质量、速度、内存权衡
T/C	后期上限组	Codex Teacher / GPT-6 Astra	仅在阶段 IV 估计能力上限，不充当真值

表 2 实验分组与比较目的

核心配对比较为 C1 对 E1、C2 对 E2（LoRA 增益），E1 对 Q1、E2 对 Q2（量化保真），Q1 对 Q2（最终本地候选），以及 A0 对 Q1/Q2（相对当前系统的质量与时间收益）。阶段 IV 中 Teacher 与云模型只作为能力上限参照；正确性仍可由执行测试、文件状态、安全约束和独立盲评共同确定，防止 Teacher 生成数据后再次为自身评分。

4 任务周期、逻辑时间与知识树半径

4.1 完整周期定义

一个周期不是任意持续若干小时的空等待，而是一条不可拆分的任务事件轨迹。周期 C 包含按顺序排列的任务、逻辑到达时间、工作区快照和验证器。单一模型变体必须从周期起点运行到终点；周期内允许保留协议规定的状态，但禁止跨实验复制未授权状态。

$$C = \{(x_i, a_i, w_i, v_i)\} \text{ for } i = 1, \dots, N$$

其中 x_i 为任务， a_i 为逻辑到达时间， w_i 为任务前工作区快照， v_i 为独立验证器。逻辑周期回放保留顺序、状态转移、任务分布和内存限制，但压缩任务之间的空闲等待；真实墙钟周期则保留实际到达间隔、设备温度、系统负载与长期资源泄漏，用于最终部署验证。

4.2 离线覆盖时长与知识半径

离线覆盖时长 h 表示胶囊从构建时刻起需要独立覆盖的未来任务窗口。若每个任务均重置且任务分布不变，墙钟时间本身不会降低模型质量；衰减来自任务分布漂移、类型扩张、知识陈旧和固定资源下的覆盖稀释。令 $d(x, D_{\text{train}})$ 表示任务 x 到训练分布中心的知识距离，则窗口 h 的知识树半径定义为任务距离的 q 分位数，默认 $q = 0.95$ 。

$$R_q(h) = \text{Quantile}_q(\{d(x_i, D_{\text{train}}) : a_i \leq h\}), q = 0.95$$

任务广度使用类别分布熵和有效类别数描述。令 $p_k(h)$ 为窗口 h 内第 k 类任务的比例：

$$H_{\text{task}}(h) = - \sum_k p_k(h) \log p_k(h); K_{\text{eff}}(h) = \exp(H_{\text{task}}(h))$$

R_q 衡量任务离训练核心有多远， K_{eff} 衡量同时覆盖多少种能力。实验必须同时记录二者，避免把任务距离与任务多样性混为同一变量。推荐窗口为 1 h、6 h、12 h、24 h、72 h 和 7 d，并采用嵌套轨迹，使短窗口任务集合是长窗口任务集合的子集。正式窗口与类别分布应由真实任务日志或预先锁定的任务日程推导。

5 固定资源约束与设备分层

公平约束是固定总运行内存而非仅固定上下文长度。总预算 B_{total} 包含模型权重、Adapter、KV Cache、检索索引、工作状态与 Harness 开销。所有组别记录配置值与实测峰值；超过预算的任务判定为资源失败。

$$B_{\text{total}} = B_{\text{weights}} + B_{\text{adapter}} + B_{\text{KV}} + B_{\text{index}} + B_{\text{state}} + B_{\text{harness}}$$

设备差异采用分层而非粗暴归一化解决。质量比较要求同一设备块内运行相同配对任务；硬件作为阻断因子进入统计模型。服务器结果可以扩大样本和检验算法质量，但服务器的原始时延、吞吐、能耗与超时率不能替代目标笔记本结论。每台设备记录 CPU、GPU、RAM/VRAM、驱动、操作系统、推理引擎、线程数、上下文、量化、功耗模式和温度。

层级	执行方式	用途	能否替代笔记本结论
L0 微基准	固定短 prompt、固定输出长度	测预填充和生成吞吐、加载时间	否
L1 逻辑周期	跳过空闲等待，完整顺序回放	质量、工具可靠性、衰减统计	仅质量部分
L2 并行重复	服务器上多个隔离 worker 各跑完整周期	缩短多次实验墙钟时间	否
L3 实时耐久	目标笔记本按真实到达时间跑满周期	热稳定、内存泄漏、真实限时成功率	是，最终验收

表 3 三级运行协议与证据边界

6 数据集与任务构成

Teacher 原始数据建议先生成约 1,500 条，经格式、执行、重复度、安全和泄漏检查后保留 1,000 至 1,200 条训练样本，另设约 150 条验证样本和至少 200 条独立测试样本。低成本试验可先使用 300/50/40 的训练、验证和测试规模。训练数据记录结构化行为轨迹而非冗长隐藏思考链：任务、工具调用、工具结果、补丁、验证结果和简短终结。

任务类别	建议训练占比	主要验证
代码搜索与定位	20%	路径、证据行、无虚构
单文件修改	25%	目标测试、最小改动、边界
多文件一致性修改	20%	跨文件契约、回归测试
测试失败诊断与修复	25%	失败解释、修复、复测
工具错误与恢复	10%	参数修正、停止条件、安全

表 4 训练任务构成建议

切分单位应为仓库 fixture、缺陷家族和任务模板，而不是单条文本。相同模板仅替换变量不能跨越训练与测试边界。正式测试集在训练开始前锁定摘要哈希；Teacher 可生成训练集，但测试真值必须由独立 fixture 与可执行验证器决定。每个任务保存 category、difficulty、knowledge_distance、logical_arrival、time_limit、allowed_tools、expected_changes 和 validation_ids，以支持后续分层统计与图表。

7 实验步骤

- 步骤 1：冻结协议：登记研究假设、模型候选、非劣效界限、周期定义、内存预算、设备清单、软件版本和随机种子。
- 步骤 2：锁定数据：生成并审查训练集；按 fixture 与缺陷家族切分；计算去重报告与数据摘要哈希。
- 步骤 3：校准 Harness：以不计入正式结果的任务验证工具协议、超时、状态重置、资源采样和失败分类。
- 步骤 4：建立基线：A0、C1、C2 在相同任务轨迹上运行；当前阶段只进行缩短逻辑周期。
- 步骤 5：LoRA 训练：第一轮使用相同数据和近似训练预算；最终候选使用至少 3 个训练随机种子。
- 步骤 6：高精度评估：E1、E2 跑相同配对周期，记录任务、工具、时间和资源原始事件。
- 步骤 7：量化部署：对同一 Adapter 构造 Q1、Q2；保持提示、工具、上下文和停止规则一致。
- 步骤 8：逻辑周期重复：在服务器上以隔离 worker 并行运行完整周期；一个周期不得跨设备切片。
- 步骤 9：目标设备确认：只对通过筛选的最终 1 至 2 个候选在笔记本上运行真实墙钟满周期。
- 步骤 10：上限对照：微调与量化稳定后加入 Teacher 和 GPT-6 Astra，使用同一验证器；云端时延单独报告。
- 步骤 11：统计与制图：从不可覆盖的 case_results.jsonl 聚合；生成置信区间、衰减曲线、Pareto 图和设备分层报告。

8 任务级指标与计算公式

8.1 严格成功与限时成功

任务 i 的严格成功要求所有验证器通过、预期文件状态满足、无越界改动且无安全违规。限时成功进一步要求端到端耗时不超过任务上限 τ_i 。

$$Y_i = I(\text{validate}_i = 1 \text{ and } \text{boundary}_i = 1 \text{ and } \text{safety}_i = 1)$$

$$S_i = Y_i * I(t_i \leq \tau_i); A_m(h) = (1 / n_h) \sum_{i \in h} S_i$$

$A_m(h)$ 为模型 m 在离线窗口 h 的限时成功率，是主质量指标。超时保留为 $S_i = 0$ ，不从样本中删除。另报告 pass@1、any-pass@3 和 stable-pass@3，但多次运行以任务为聚类单位。

8.2 工具、输出与安全

$$\text{ToolValid} = N_{\text{valid_tool_calls}} / N_{\text{all_tool_calls}}$$

$$\text{OutputComplete} = N_{\text{complete_final_outputs}} / N_{\text{all_attempts}}$$

$$\text{RepeatRate} = N_{\text{redundant_tool_calls}} / N_{\text{all_tool_calls}}$$

同时记录平均工具调用数、工具参数 Schema 通过率、验证失败后的恢复率、越界修改次数和未授权操作次数。安全指标采用硬门槛：任何越界文件修改、禁止命令或未授权外部操作均使该运行失败，并单独计数。

8.3 延迟、吞吐与资源

$$\text{TPS}_{\text{gen}} = N_{\text{generated_tokens}} / T_{\text{generation}}$$

$$\text{TaskThroughput} = N_{\text{completed_tasks}} / T_{\text{wall_clock}}$$

$$\text{MemoryUtilization} = B_{\text{peak}} / B_{\text{total}}$$

延迟报告模型加载、首 token、端到端 P50/P90/P95、成功任务中位数以及超时比例。仅统计成功任务的平均延迟会产生幸存者偏差，因此主指标使用限时成功率；超时任务在时间到事件分析中视为右删失。吞吐只在设备、并发度和批处理策略相同时直接比较。

9 后训练与量化指标

训练记录包括 train/validation loss、训练 token 数、epoch、学习率、LoRA rank/alpha/dropout、batch size、梯度累积、随机种子、训练时长、吞吐、峰值内存和 checkpoint 选择规则。训练 loss 仅用于诊断，不作为产品验收指标。LoRA 通过冻结基础权重并训练低秩增量降低任务适配成本 [1]；QLoRA 进一步通过量化基础权重降低训练内存 [2]。

$$\text{Gain}_{\text{LoRA}} = A_{\text{finetuned}} - A_{\text{base}}$$

$$\Delta_{\text{quant}} = A_{\text{quantized}} - A_{\text{high_precision}}$$

$$\text{Retention}_{\text{quant}} = A_{\text{quantized}} / A_{\text{high_precision}}$$

$$\text{Speedup} = \text{MedianLatency}_{\text{reference}} / \text{MedianLatency}_{\text{candidate}}$$

$$\text{MemoryReduction} = 1 - B_{\text{peak_candidate}} / B_{\text{peak_reference}}$$

$$\text{SizeReduction} = 1 - \text{FileSize}_{\text{candidate}} / \text{FileSize}_{\text{reference}}$$

成功率差优先报告百分点而非相对百分比。量化非劣效性令 $\Delta_q = A_{\text{quantized}} - A_{\text{high_precision}}$ ；若其配对 95% 置信区间下界高于 $-\delta_q$ ，则量化版通过。初始建议 $\delta_q = 0.05$ ，即最多允许下降 5 个百分点。

10 精确度衰减与模型差距

时间轴使用 $\log_2(h)$ ，使指标可解释为离线覆盖时长每翻倍的变化。模型 m 从 h_1 到 h_2 的平均衰减率定义为：

$$\lambda_{\text{m}}(h_1, h_2) = [A_{\text{m}}(h_1) - A_{\text{m}}(h_2)] / \log_2(h_2 / h_1)$$

λ 的单位为每次时间翻倍下降的成功率百分点。模型差距定义为：

$$G(h) = A_{\text{large}}(h) - A_{\text{small}}(h)$$

是否存在差距扩大通过模型乘 $\log_2(h)$ 的交互项检验，而不是观察两条线后主观判断。对二元成功结果使用含任务家族和 fixture 随机截距的混合效应逻辑模型：

$$\text{logit } P(S_i=1) = \beta_0 + \beta_M M + \beta_H \log_2(h) + \beta_{MH} M \cdot \log_2(h) + u_{\text{family}} + u_{\text{fixture}}$$

β_{MH} 是核心参数：其方向与区间决定小模型和大模型差距是否随周期显著变化。另报告归一化衰减曲线面积 $AUC_{\log}$ 、跌破验收阈值 a^* 的首次离线窗口，以及相对初始成功率的半衰窗口。

$$H_{\text{threshold}}(a^*) = \inf\{h : A_m(h) < a^*\}$$

11 统计推断与试验次数

每个模型乘配置乘窗口的 30 个独立任务实例是最低试验门槛，不是精确估计保证。成功率接近 0.5 时， $n = 30$ 的正态近似 95% 误差约为 ± 18 个百分点。若希望单一比例的误差约为 ± 5 个百分点，最保守近似样本量为：

$$n \approx z_{(0.975)}^2 \cdot p(1-p) / e^2 = 1.96^2 \cdot 0.25 / 0.05^2 \approx 385$$

因此采用自适应分级：30 个实例用于最低周期与流程筛查，100 至 160 个用于候选初筛，约 300 至 400 个用于 5 个百分点级正式判断。正式停止规则必须预注册；同一任务多次运行不能当作完全独立样本。二元比例报告 Wilson 95% 区间 [6]，同任务模型差使用配对 bootstrap [5] 和 McNemar 检验；bootstrap 以任务或完整周期为聚类单位。延迟报告中位数、四分位距、P90/P95，并对超时使用右删失时间到事件曲线。

$$\text{WilsonCI} = (p_{\text{hat}} + z^2/(2n) \pm z \cdot \sqrt{p_{\text{hat}}(1-p_{\text{hat}})/n + z^2/(4n^2)}) / (1 + z^2/n)$$

最终候选至少训练 3 个随机种子，分别报告结果、均值、标准差、最好与最差值。不能仅选择最好 seed。若周期具有状态依赖，统计单位提升为完整周期；可在服务器生成至少 30 条独立逻辑周期，并在目标笔记本对最终候选执行较少但完整的真实墙钟周期。

12 0.8B 对较大候选的非劣效判定

令 $\Delta_s = A_{0.8B} - A_{large}$ 。初始质量非劣效界限设为 $\delta_s = 0.05$ ；当 Δ_s 的配对 95% 置信区间下界高于 -0.05 时，0.8B 在该周期满足质量非劣效。仅满足质量条件仍不足以入选，0.8B 还必须提供显著部署收益。

指标	0.8B 相对较大候选的初始门槛
限时成功率	配对 95% CI 下界 > -5 个百分点
工具参数合法率	下降不超过 2 个百分点，且绝对值 $\geq 98\%$
输出完整率	$\geq 98\%$
安全违规	两者均必须为 0
目标设备 P95 任务时间	至少改善 30%
峰值总内存	显著降低且不超过 B_{total}
训练种子稳定性	最大成功率差不超过 8 个百分点

表 5 0.8B 候选的联合验收门槛

高 token/s 不等于低任务耗时。小模型可能因错误工具选择、重复搜索和多次修复产生更长的端到端时间，因此主要产品指标仍是限时成功率，速度收益以完整任务延迟而非单独生成吞吐衡量。

13 长周期与硬件差异的工期压缩方案

单模型必须跑满周期的约束予以保留，但将“周期完整性”与“实验必须按真实墙钟等待”分离。建议采用以下组合，而不是把 Blackwell 服务器耗时线性换算为笔记本耗时。

- 固定事件周期：所有模型处理完全相同的任务序列、状态转移和逻辑时间；任务间空闲等待在逻辑回放中压缩。
- 并行重复而非切片：服务器上启动多个隔离 worker，每个 worker 独立跑完整周期；不能把一个有状态周期拆到多台设备后拼接。
- 质量与性能分离：服务器用于质量、工具可靠性和衰减统计；原始时延、功耗、热稳定和真实超时仅在同设备内比较。
- 候选漏斗：工程冒烟不计入正式结论；明显违反安全、内存或最低成功率的候选可预注册提前淘汰，只有最终 1 至 2 个模型进入昂贵笔记本周期。
- 目标设备少量确认：服务器完成至少 30 条独立逻辑周期后，笔记本对最终候选运行 3 至 5 个真实墙钟完整周期；若设备内变异过大再追加。
- 共同任务与配对设计：相同周期在所有模型上重复，显著降低模型差估计方差。
- 设备校准只作辅助：固定 prompt 的预填充/生成吞吐可描述硬件差异，但不得用一个比例校正后宣称服务器等价于笔记本。
- 部署域复验：若最终胶囊面向多类设备，则每类目标设备独立构成一个统计层，并检验 $model \times device$ 交互。

以用户示例为例：笔记本 6 小时约完成 30 个任务，Blackwell 服务器可完成数百任务。服务器可以并行完成正式逻辑周期与统计重复，但至少一个最终候选必须在笔记本上跑满预注册的真实周期。若笔记本一次周期为 6 小时，3 个周期约需 18 小时，可安排为无人值守夜间运行；这比所有模型、所有量化档和所有 seed 都在笔记本跑 30 个周期大幅缩短工期，同时仍保留部署有效性。

14 结果记录与图表

每次实验生成不可覆盖的 manifest.json、training_metrics.jsonl、case_results.jsonl、summary.json、summary.md 与 charts/。manifest 至少记录 Git commit、数据摘要、模型与 Adapter 哈希、量化、推理参数、周期 ID、设备指纹、内存预算、随机种子和预注册停止规则。所有图表从原始 JSONL 重建。

图表	横轴	纵轴/编码	主要结论
限时成功率曲线	log2 离线时长	成功率 + 95% CI	各模型衰减轨迹
模型差距曲线	log2 离线时长	G(h) + 配对 CI	差距是否扩大
知识半径曲线	R_0.95	限时成功率	分布外衰减
类别热力图	任务类别	模型/周期；颜色为成功率	弱项与覆盖空洞
质量-延迟 Pareto	P95 任务时间	限时成功率；点大小为内存	工程最优配置
量化保留率	量化档	Retention_quant	最低可接受精度
时间到完成曲线	任务耗时	未完成比例	纳入超时的稳定性
训练曲线	训练 step/token	train/validation loss	收敛与过拟合
Seed 波动图	模型与量化	各 seed 成功率	训练稳定性

表 6 预注册结果图表

图表颜色固定：灰色为 4B 运行基线，蓝色为未微调对照，绿色为高精度 LoRA，橙色为量化部署，红色为失败、超时或安全违规。比例图默认使用 0% 至 100% 纵轴；任何截断坐标必须显式标注。

15 有效性威胁与限制

- 硬件外推：GPU 服务器的质量结果通常可复用，但时延、热稳定、功耗与超时不能直接外推到 CPU 笔记本。
- 任务漂移建模：逻辑离线窗口只近似未来任务分布，必须用真实部署日志进行前瞻复验。
- Teacher 偏差：Teacher 生成训练数据并参与评分会高估相似风格模型，应使用独立验证器和盲评。
- 重复依赖：同一任务、fixture 或周期的多次运行相关，必须聚类统计，禁止扩大名义样本量。
- 配置交互：量化、上下文、并发、Adapter 和推理引擎可能与设备交互，跨设备结果必须分层。
- 小样本：n = 30 只能用于筛查；未达到所需置信区间宽度时，结论标记为探索性。
- 时间与知识因果：若任务分布不变且状态重置，墙钟时间本身不造成质量衰减；报告必须说明衰减来自何种漂移或状态压力。

16 推荐执行决策

当前工程立即实施阶段 I：完成训练数据 Schema、实验日志 Schema、固定任务事件周期和资源采集；使用 40 个独立案例的缩短逻辑周期校准 0.8B 与约 1.5B/2B。完成 LoRA 后进入阶段 II，每个最终候选使用至少 3 个训练种子。量化稳定后进入阶段 III，在服务器执行大样本独立逻辑周期，并只让最终 1 至 2 个候选在目标笔记本执行真实墙钟满周期。Teacher、GPT-6 Astra 与完整精确度衰减研究属于阶段 IV，不阻塞当前工程选型，但从现在起使用同一 case_result 和 manifest 数据契约。

参考文献

- [1] Hu, E. J., et al. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685, 2021.
<https://arxiv.org/abs/2106.09685>
- [2] Dettmers, T., et al. QLoRA: Efficient Finetuning of Quantized LLMs. arXiv:2305.14314, 2023. <https://arxiv.org/abs/2305.14314>
- [3] Liang, P., et al. Holistic Evaluation of Language Models. arXiv:2211.09110, 2022. <https://arxiv.org/abs/2211.09110>
- [4] Mattson, P., et al. MLPerf Training Benchmark. arXiv:1910.01500, 2020. <https://arxiv.org/abs/1910.01500>
- [5] Efron, B. Bootstrap Methods: Another Look at the Jackknife. The Annals of Statistics, 7(1), 1-26, 1979.
- [6] Wilson, E. B. Probable Inference, the Law of Succession, and Statistical Inference. Journal of the American Statistical Association, 22(158), 209-212, 1927.
- [7] OpenAI. GPT-6 Astra Model. OpenAI API Documentation, accessed 2026-09-09.
<https://developers.openai.com/api/docs/models/gpt-6-astra>